Mendelova univerzita v Brně
Provozně ekonomická fakulta

Příloha k diplomové práci - trénink modelu RoBERTa

Diplomová práce

Vedoucí práce:
doc. Ing. Oldřich Trenz, Ph.D.

Bc. Vojtěch Mahdal

Brno 2026

1 Výběr technologie

Datové sady pro trénink

Pro trénink modelu sentimentu je klíčový výběr vhodné datové sady, jelikož kvalita a vyváženost dat přímo ovlivňují přesnost výsledného modelu. Datová sada by měla obsahovat reprezentativní a vyvážené vzorky, aby model dokázal správně generalizovat. (Géron a spol, 2019)

Pro účely tréninku byly porovnány konverzační datové sady zaměřené na sentiment a emoce, jejichž přehled uvádí tabulka níže.

Tabulka 1: Porovnání vybraných datasetů pro konverzační sentiment a emoce

Dataset	Velikost	Label space	Vyváženost	Doména	Jazyk
chat-sentiment (HF)	∼28,8k	3 (pos/neu/neg)	nevyv., více neu.	chat	EN
EmpatheticDialogues	∼25k	32 emocí	spíše nevyv.	emoční situace	EN
conversation-emotion	∼5–10k	multi-label	nevyv.	krátké konverzace	EN
DistillChat v1	∼86,2k	žádné	nevyv.	casual chaty	EN
Chat Sentiment Dataset	∼500	3 (pos/neu/neg)	poměrně vyv.	krátké chaty	EN

Zdroj: Autorské zpracování; zdroje datasetů: (Hugging Face - yuncongli), (Facebook AI), (Hugging Face - Sven Maibaum), (Hugging Face - fanqiwan)

Pro postupné dotrénování modelu byly zvoleny datové sady chat-sentiment--analysis, EmpatheticDialogues a Chat Sentiment Dataset, které pokrývají chatový styl komunikace se třemi třídami sentimentu (positive, neutral, negative). Podrobný popis jejich zpracování a jednotlivých trénovacích etap je uveden v kapitole věnované implementaci.

Knihovna pro práci s modely

Pro výběr vhodného nástroje NLP byly porovnány moderní knihovny a frameworky s ohledem na přesnost, výkon, flexibilitu a podporu pokročilých modelů. Na základě článků (GeeksforGeeks, 2025a) a (Spot Intelligence, 2024) byly mezi sebou srovnány knihovny Hugging Face Transformers, spaCy, NLTK, TextBlob a Stanford CoreNLP.

Tabulka 2: Srovnání NLP nástrojů (1 = nízké, 3 = vysoké)

Nástroj	Přesnost	Výkon	Flexibilita	Snadnost použití	Jazyková podpora
Hugging Face Transformers	3	2	3	1	2
spaCy	2	3	2	2	2
NLTK	1	1	1	3	1
TextBlob	1	1	1	3	1
Stanford CoreNLP	2	1	1	1	3

Zdroj: Autorské hodnocení na základě (GeeksforGeeks, 2025a) a (Spot Intelligence, 2024)

Hodnocení na škále 1 až 3 je pouze orientační a kvalitativní: vychází z porovnání uvedených ve zdrojích (GeeksforGeeks, 2025a) a (Spot Intelligence, 2024) a vyjadřuje relativní pořadí nástrojů, nikoli výsledek vlastního měření nebo jednotné metodiky.

Jako hlavní knihovna byla zvolena **Hugging Face Transformers**, a to z důvodu přístupu k moderním předtrénovaným modelům (BERT, RoBERTa, BART), možnosti jejich jemného doladění, vysoké přesnosti, aktivního vývoje a rozsáhlé komunity. Tato knihovna je vhodná pro všechny modelové funkce systému, tedy pro analýzu sentimentu, rozpoznávání entit i kategorizaci témat. Pro detekci osobních údajů je doplněna o specializovaný nástroj popsaný v samostatné sekci. Knihovna spaCy je přitom použitelná jako alternativní zdroj NER modelu a je rovněž využívána uvnitř zvoleného anonymizačního nástroje. Hugging Face Transformers patří v současnosti mezi nejpoužívanější nástroje v oblasti NLP, což zajišťuje relevanci výsledků práce vzhledem k aktuálním studiím. (Hugging Face, 2022) (J. Didin, 2025)

Výpočetní infrastruktura

Pro trénink a fine-tuning modelu byla využita národní výpočetní infrastruktura **MetaCentrum** spravovaná sdružením CESNET, která poskytuje výkonné servery, datová úložiště a prostředí JupyterLab dostupné přes webový prohlížeč. MetaCentrum je bezplatně dostupné pro akademické pracovníky a studenty. Inference předtrénovaných modelů (NER, kategorizace témat) a provoz výsledného systému jsou výpočetně méně náročné než trénink a lze je provozovat i na běžném hardwaru. (Metacentrum, 2025)

Volba modelu

Pro analýzu sentimentu byl na základě porovnání modelů BERT, RoBERTa a DistilBERT zvolen model **RoBERTa**. Hlavním důvodem výběru jsou architektonické vlastnosti modelu a porovnání jeho výsledků s ostatními modely řady BERT. RoBERTa staví přímo na architektuře BERT, avšak odstraňuje úlohu *Next Sentence Prediction*, využívá dynamické maskování a je trénována na výrazně větším korpusu (160 GB oproti 16 GB u BERT), což jí umožňuje dosahovat vyšší kvality predikcí. (Kotamraju, 2022)

Uvedené hodnoty F1 pocházejí z citovaného srovnávacího zdroje, který nespecifikuje konkrétní benchmark ani způsob měření, a slouží proto jen jako hrubá orientace, nikoli jako podklad rozhodnutí. Rozhodující byly architektonické vlastnosti modelů; skutečná přesnost použitých modelů je vyhodnocena samostatně v kapitole Testování systému. Ve srovnání s DistilBERTem sice RoBERTa vyžaduje více zdrojů, avšak poskytuje stabilně vyšší přesnost, což je pro účely této práce prioritní. Vzhledem k vysoké přesnosti, robustnosti a široké podpoře v knihovně Hugging Face byl model RoBERTa zvolen jako základní model pro dotrénování klasifikátoru sentimentu. (Swiftorial, 2025)

Tabulka 3: Porovnání modelů BERT, RoBERTa a DistilBERT

Vlastnost	**BERT**	**RoBERTa**	**DistilBERT**
Architektura	12 vrstev, ∼110M parametrů, NSP	12 vrstev, bez NSP, dynamické maskování, větší korpus	6 vrstev, ∼66M parametrů, distilace
Orientační F1 (dle zdroje)	∼92 %	∼94 %	∼91 %
Rychlost	střední	srovnatelná s BERT	∼60 % rychlejší
Použití	obecné úlohy	priorita: přesnost	priorita: rychlost

Zdroj: (Swiftorial, 2025)

2 Trénink modelu

Pro dosažení úspěšného natrénování modelu bylo nezbytné postupovat podle předem definovaných kroků. Ty zahrnovaly zprovoznění prostředí pro provádění experimentů, návrh vhodné struktury kódu umožňující načtení datasetu, provedení anonymizace a vyvážení dat, následné postupné trénování modelu a jeho finální testování.

2.1 Metacentrum

Při provádění experimentů bylo nezbytné zajistit přístup do MetaCentra, protože lokální hardware by nedosahoval výkonu, kterého je možné získat prostřednictvím externích serverů. Díky tomu, že CESNET umožňuje studentům bezplatné využívání platformy, nebyl problém s registrací ani se zprovozněním testovacího serveru. Pro potřeby platformy JupyterHub byl zvolen image „Simple Jupyter Images“ vzhledem k jeho jednoduchosti pro trénink. V dalším kroku bylo zřízeno persistentní úložiště, aby po restartu serveru nedocházelo k samovolnému mazání dříve vytvořených experimentů. Nakonec bylo nutné přiřadit výpočetní zdroje. Pro účely trénování modelů, fine-tuningu a dalších operací spojených s realizací této práce bylo dostačující nastavení: CPU o 6 jádrech, paměť RAM 32 GB a GPU Nvidia A40. S tímto nastavením byl následně vytvořen testovací server s prostředím JupyterLab. (Metacentrum, 2025)

2.2 Příprava Kernelu

Pro realizaci skriptů a automatizaci operací v prostředí JupyterLab bylo nezbytné nainstalovat příslušné knihovny a nakonfigurovat odpovídající kernel. Aby se předešlo opakované manuální instalaci po každém restartu systému, byl vytvořen automatizační skript s názvem setup_venv_transformers.sh (viz příloha), který provádí instalaci všech potřebných komponentů. Skript je nejprve nutné označit jako spustitelný příkazem *chmod +x setup_venv_transformers.sh* a následně spustit jeho instalaci prostřednictvím příkazu *./setup_venv_transformers.sh*. (**?**)

2.3 Struktura kódu

Než mohl být model RoBERTa použit pro úlohu klasifikace sentimentu, bylo nutné připravit a transformovat zdrojová data do vhodné podoby. Tato fáze zahrnuje několik kroků, od načtení a očištění textů přes extrakci relevantních informací až po jejich tokenizaci do formátu, který lze zpracovat neuronovou sítí.

Hlavním cílem této části bylo zajistit, aby data neobsahovala citlivé informace, aby jednotlivé třídy sentimentu byly vyváženě zastoupeny a aby texty byly jednotně zpracovány z hlediska délky i struktury. Součástí procesu byla také implementace

funkcí pro maskování osobních údajů, převod textových popisů sentimentu na číselné štítky a následné rozdělení datasetu na trénovací, validační a testovací část.

K tokenizaci byl použit předtrénovaný tokenizer modelu RoBERTa, který převádí text na sekvence tokenů odpovídající slovům nebo jejich částem. Tokenizace zároveň zajišťuje normalizaci délky vstupů pomocí „paddingu“ a „truncation“, což je nezbytné pro dávkové zpracování v trénovací fázi. (?)

Celý postup přípravy dat tak vytváří konzistentní, očištěný a modelu přizpůsobený dataset, který slouží jako vstup pro následný proces trénování a vyhodnocování výkonu modelu.

Načtení datasetu

V první části skriptu je zapotřebí nahrát datovou sadu, která bude použita na trénování modelu. V případě práce byly použity dva způsoby, a to dataset z veřejného repozitáře (Hugging Face), nebo dataset ve formátu CSV.

Dataset z veřejného repozitáře (Hugging Face) je načítán pomocí knihovny „datasets“, která umožňuje přímé stažení dat, kontrolu struktury a práci v efektivním formátu založeném na paměťovém mapování. Stažení probíhá automaticky, včetně metadat a anotací. (?)

Dataset ve formátu CSV namísto toho pochází z externího exportu, tedy například z firemních chatů, zákaznické komunikace či synteticky vytvořených souborů. V případě datových setů použitých v této práci byl tento import použit i kvůli chybějící podpoře „Hugging Face“ u zdrojů, jako je Kaggle či GitHub. V tomto formátu je dataset načítán pomocí knihovny „Pandas“, která umožňuje flexibilní manipulaci s tabulkovými daty, detekci chybějících hodnot a rychlé filtrování textového obsahu.

Maskování citlivých údajů

Bez ohledu na původ datasetu mohou jednotlivé textové záznamy obsahovat citlivé osobní údaje. Kvůli tomu byla ve druhém kroku definována funkce „mask_sensitive“, která nahrazuje v textu citlivé informace, jako jsou e-maily, URL, telefonní čísla, uživatelská jména, čísla nebo jména osob, generickým identifikátorem typu jako je <NAME>, <PHONE>, <EMAIL>, <ADDRESS>. Maskování je zapotřebí z důvodu ochrany soukromí a zabraňuje tomu, aby se model během trénování učil citlivé informace namísto určování sentimentu. (?)

```
1 import re
2
3 def mask_sensitive(text: str) -> str:
4     if not isinstance(text, str):
5         return ""
6     text = re.sub(r"\b[A-Za-z0-9._%+-]+@[A-Za-z0-9.-]+\.[A-Z|a-z]{2,}\b", "<EMAIL
      >", text)
```

```
    text = re.sub(r"http\S+|www\.\S+", "<URL>", text)
    text = re.sub(r"\+?\d[\d\-\s]{7,}\d", "<PHONE>", text)
    text = re.sub(r"@[A-Za-z0-9_]+", "<USER>", text)
    text = re.sub(r"\b\d{4,}\b", "<NUMBER>", text)
    text = re.sub(r"(?<![.!?]\s)(?<!^)(\b[A-Z][a-z]+)", "<NAME>", text)
    text = re.sub(r"\s+", " ", text).strip()
    return text
```

Část kódu 1: Funkce maskování citlivých údajů

Mapování datových struktur a anotací

Pro správnou funkčnost NLP modelů je nutné transformovat text a jeho anotace do formátu, který očekává daný model. Hlavní podstatou je převod textových anotací na číselné hodnoty, tedy:

- negative → 0
- neutral → 1
- positive → 2

Kromě toho je nutné sjednotit struktury dat mezi různými datovými sadami, očistit text od nežádoucích prvků, normalizovat délku textů a připravit metadata potřebná k tokenizaci.

Tokenizace pro RoBERTu

Tokenizace představuje krok, ve kterém se text převádí na sekvenci tokenů, se kterými může model pracovat.

Tokenizér RoBERTa převede texty na tokeny, aplikuje padding a případně zkrátí delší texty. Díky tomu je následně délka vstupu standardizována.

Výsledkem je dávková struktura obsahující matice tokenů, labelů a attention masek, která slouží jako vstupní reprezentace pro následné trénování na daném modelu. (**?**)

Stratifikované rozdělení datasetu

Dataset se v dalším kroku rozdělí na trénovací, validační a testovací část.

Pro datasety byl použit následující princip rozdělení, tedy typicky 70–80 % dat na trénovací část, 10–20 % na validační část a zbytek na testování.

Dodržení tohoto rozdělení je nezbytné pro objektivní vyhodnocení modelu.

- **trénovací data** slouží ke skutečnému učení modelu
- **validační data** slouží ke sledování průběžné přesnosti a minimalizaci přetrénování
- **testovací data** umožňují nezávislé vyhodnocení po dokončení tréninku

(?)

Příprava dat pro trénovací pipeline

Finální krok přípravy dat spočívá ve spojení všech výše uvedených kroků do jednotné pipeline, která je schopna poskytovat modelu vstupy ve správné formě.

Ta zahrnuje převedení tokenizovaných dat do formátu „Dataset“ nebo „PyTorch DataLoader“. Kromě toho zahrnuje vytvoření datových struktur očekávaných modelem, inicializaci a konfiguraci trénovacího procesu (loss funkce, optimalizátor, metriky).

Trénování modelu a konfigurace trénovací pipeline

Po přípravě dat, jejich anonymizaci a tokenizaci následuje fáze vlastního trénování modelu.

Trénování probíhalo s využitím třídy „Trainer“, která automatizuje většinu kroků potřebných k učení modelu a výrazně zjednodušuje experimentování.

Konfigurace trénovacího procesu byla nastavena prostřednictvím „TrainingArguments“, kde se definují klíčové hyperparametry důležité pro trénování.

Jsou jimi:

- počet epoch
- velikost dávky (batch size)
- způsob výčtu metrik
- strategie učení (learning rate schedule)
- použití GPU či CPU

Tyto parametry mají zásadní vliv na výslednou kvalitu modelu i na stabilitu trénovacího procesu. Například vyšší počet epoch umožňuje modelu naučit se více vzorů v datech, avšak zvyšuje riziko přetrénování, zatímco velikost dávky (batch size) ovlivňuje rychlost učení a stabilitu gradientů.

Průběh trénování začíná poté, co „Trainer“ po inicializaci třídy spustí samotný trénink nad trénovací sadou dat. Model iterativně aktualizuje své váhy na základě minimalizace ztrátové funkce. V rámci každé epochy je současně počítána metrika na validační sadě, což umožňuje včas odhalit problémy s přetrénováním.

Validace modelu a detekce přetrénování

Validace představuje nedílnou součást trénovacího procesu. Jejím hlavním cílem je sledovat, jak dobře si model vede na datech, která neviděl během tréninku. Tato kon-

trola je klíčová pro to, aby model nebyl přizpůsoben příliš úzce trénovacím vzorům, ale aby dokázal zobecňovat i nová data.

Po dokončení všech trénovacích epoch je model otestován na testovacím datasetu. Tento krok je zásadní, protože poskytuje nezávislý pohled na výkon modelu na datech, která nebyla využita ani při tréninku, ani při validaci.

Hodnocení naučeného modelu a metriky

Pro kvalitní posouzení toho, jak dobře model funguje, byly využity různé metriky běžně používané v oblasti zpracování přirozeného jazyka. Jednotlivé metriky poskytují odlišné informace o tom, jak model vyhodnocuje texty a jak přesně klasifikuje jednotlivé třídy, tedy „Precision“, „Recall“, „F1-score“.

Kromě toho je implementována i konfuzní matice pro grafickou i tabulkovou reprezentaci toho, jak model klasifikoval jednotlivé třídy.

Uložení modelu

Finální částí skriptu je uložení ve formátu zahrnujícím váhy natrénovaného modelu, konfiguraci modelu, tokenizer a metadata o trénování. Tento formát umožňuje model kdykoliv znovu načíst a použít bez nutnosti opakovat trénink.

2.4 První etapa – trénink prvního datasetu

V první fázi byla použita data z veřejného datasetu **yuncongli/chat-sentiment--analysis** dostupného na Hugging Face. Tento dataset obsahuje přibližně 28 772 řádků (training split). Každý řádek reprezentuje jednu chatovou výpověď spolu s anotací sentimentu, což umožňuje efektivní trénink klasifikačního modelu pro sentiment v konverzačním kontextu.

Data byla načtena přímo z Hugging Face přes rozhraní datasets a následně rozdělena na trénovací, validační a testovací sady. Díky této stratifikaci bylo možné model nejen trénovat, ale i průběžně validovat jeho výkon a nakonec testovat na nezávislé sadě, čímž se minimalizuje riziko přeučení (overfittingu).

Transformace dat pro trénink

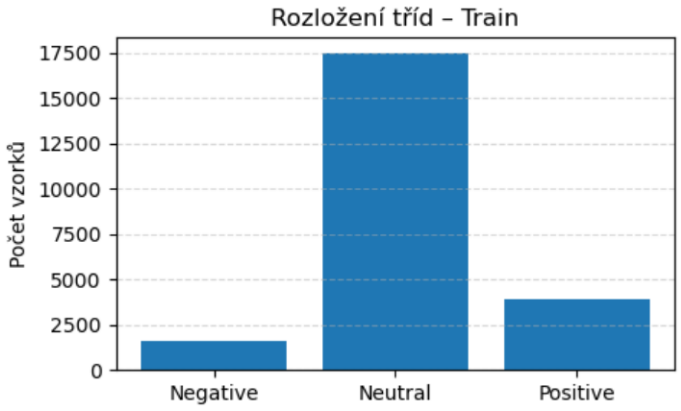
Pro použití v trénovacím notebooku byla data transformována do formátu vhodného pro modelování s předtrénovaným transformérem. Konkrétně bylo pro každý záznam provedeno:

- Složení textu instrukce a vstupu
  - Ve zmíněném datasetu se nachází label „instruction“ a label „input“. V trénovacím procesu byly tyto dvě části spojeny do jedné textové sekvence. Tento přístup umožňuje využít sílu modelů instrukčně-vstupních promptů, což může zlepšit učení kontextu a zaměření na relevantní informace.

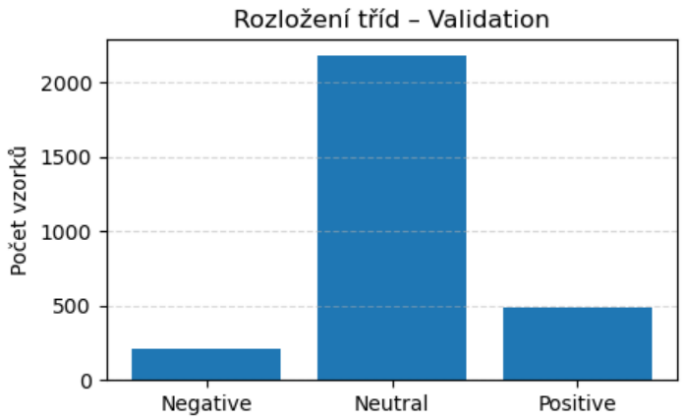
- Přiřazení labelu
  - Sentimentová anotace (např. „positive“, „neutral“, „negative“) byla použita jako cílové vyjádření, tedy **output** pro tréninkový proces. Tento label je klíčový pro trénink klasifikační vrstvy modelu.

Analýza zastoupení jednotlivých sentimentů

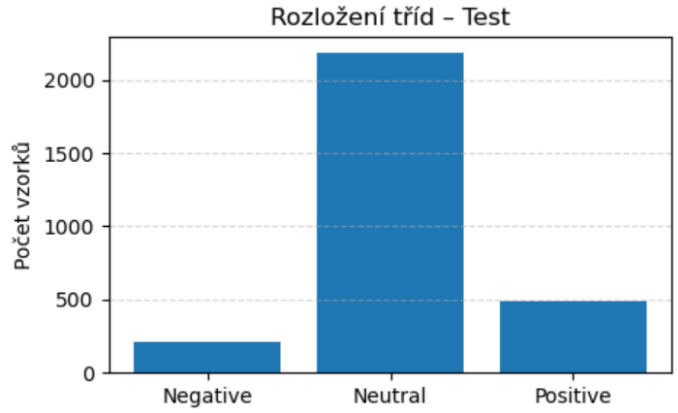
Po transformaci dat byla provedena analýza rozložení sentimentů v jednotlivých sadách (train, validation, test). Ukázalo se, že nejvíce zastoupeným sentimentem je **neutral**, což je typické pro chatové konverzace, kde mnoho vět nevyjadřuje extrémní emoční náboj ani silný pozitivní či negativní sentiment. Toto nerovnoměrné rozdělení tříd je důležité brát v úvahu, protože může ovlivnit jak metriky modelu, tak jeho schopnost generalizace.



Obrázek 1: Train - Class distribution: Negative: 1647 (7,16 %) Neutral : 17443 (75,78 %) Positive: 3927 (17,06 %)
Zdroj: Autorské zpracování



Obrázek 2: Validation - Class distribution: Negative: 206 (7,16 %) Neutral : 2180 (75,77 %) Positive: 491 (17,07 %)
Zdroj: Autorské zpracování



Obrázek 3: Test - Class distribution: Negative: 206 (7,16 %) Neutral : 2181 (75,78 %) Positive: 491 (17,06 %)
Zdroj: Autorské zpracování

Nastavení tréninku

Po přípravě dat a analýze zastoupení sentimentu byl spuštěn trénink samotného modelu.

Během tréninku bylo pravidelně vyhodnocováno chování modelu na validační sadě, což umožnilo monitorovat metriky, jako jsou ztráta (loss) a přesnost (accuracy), a identifikovat případný overfitting.

Výsledky

Výsledný model byl po dokončení tréninku uložen pod názvem „roberta-sentiment“ (viz příloha A.1). Tímto názvem je model následně možné využít pro inferenci i další fáze výzkumu.

Tabulka 4: Výsledky vyhodnocení modelu na testovacích datech

Metrika	**Hodnota**
Eval loss	0,4481
Accuracy	0,9243
Precision	0,9282
Recall	0,9243
F1-score	0,9257
Runtime (s)	5,2610
Vzorky za sekundu	547,0470
Kroky za sekundu	34,2140
Počet epoch	3

Tabulka 5: Ukázka predikcí sentimentu modelu

Text	**Negative**	**Neutral**	**Positive**
I am so happy today! Everything went perfectly.	0,0006	**0,9137**	0,0856
I feel so sad and disappointed.	**0,5749**	0,4212	0,0038
It's just an ordinary day, nothing special happened.	0,0013	**0,9984**	0,0003
I'm frustrated and angry about this situation.	0,0227	**0,9767**	0,0006
I'm nervous about tomorrow's meeting.	0,0007	**0,9990**	0,0003

Protože původní model nebyl natrénován optimálním způsobem a nebyla při tom zohledněna nevyváženost tříd v datasetu, začala se po dalším trénování výrazně projevovat nepřesnost ve výsledcích. Model měl tendenci upřednostňovat početně silnější třídy, což negativně ovlivňovalo celkovou přesnost klasifikace.

Z tohoto důvodu byly vypočítány váhy jednotlivých tříd, které byly následně použity při opětovném trénování modelu. Výsledný model byl pojmenován roberta-sentiment_dataset1 (viz příloha A.2).

Po úpravě skriptu a zavedení vyvážení tříd bylo dosaženo uspokojivějších výsledků. Jak je patrné z tabulky predikcí, rozdělení výstupů je nyní rovnoměrnější, zejména mezi pozitivními a neutrálními třídami. Přesto se mohou v některých případech stále objevovat chybné klasifikace, a proto bude model dále zlepšován opětovným trénováním na novém datasetu, jehož cílem je tyto rozdíly ještě více doladit.

Tabulka 6: Počet vzorků a váhy tříd

Třída	Počet vzorků	Váha třídy
negative	1647	0,831
neutral	17443	1,982
positive	3927	0,187

Tabulka 7: Výsledky vyhodnocení modelu na testovacích datech (roberta-sentiment_dataset1)

Metrika	Hodnota
Eval loss	0,5240
Accuracy	0,9277
Precision	0,9286
Recall	0,9277
F1-score	0,9281
Runtime (s)	6,0860
Vzorky za sekundu	472,8890
Kroky za sekundu	59,1520
Počet epoch	3

Tabulka 8: Ukázka predikcí sentimentu modelu (roberta-sentiment_dataset1)

Text	Negative	Neutral	Positive
I am so happy today! Everything went perfectly.	0,0005	0,0039	**0,9956**
I feel so sad and disappointed.	**0,9946**	0,0049	0,0005
It's just an ordinary day, nothing special happened.	0,0045	**0,9931**	0,0024
I'm frustrated and angry about this situation.	0,0524	**0,9457**	0,0019
I'm nervous about tomorrow's meeting.	0,4178	**0,5802**	0,0020

2.5 Druhá etapa - emphatetic_dialogues

V této etapě proběhl fine-tuning modelu, který byl natrénován v první etapě, na novém datasetu, což umožnilo jeho další přizpůsobení specifickým datům a kontextu.

Na rozdíl od prvního datasetu bylo v této etapě nutné dataset s názvem „empathetic_dialogues“ stáhnout z platformy Kaggle. Po jeho stažení následoval import CSV souboru přímo do pracovního prostředí JupyterHub, což umožnilo další zpracování a analýzu dat.

CSV soubor se načítá pomocí knihovny pandas, která poskytuje jednoduché a efektivní nástroje pro práci s tabulkovými daty. Podobně jako u předchozího datasetu z knihovny Hugging Face jsou i zde data rozdělena do tří základních částí: trénovací, validační a testovací sady. Toto rozdělení je klíčové pro správný průběh trénování modelu, zajištění jeho schopnosti generalizace a pro následné hodnocení přesnosti a kvality predikcí.

Transformace dat pro trénink

Na rozdíl od prvního datasetu, kde byly sentimenty již rozděleny do tří kategorií (pozitivní, negativní a neutrální), bylo v případě tohoto datasetu nutné provést transformaci labelů. Dataset totiž obsahuje 32 různých emocí, které bylo potřeba seskupit tak, aby každá spadala do jedné ze tří základních kategorií sentimentů.

```
emotion2label = {

    # Negative

    "sad": 0, "angry": 0, "afraid": 0, "anxious": 0, "ashamed": 0, "disgusted": 0,

    "embarrassed": 0, "guilty": 0, "jealous": 0, "lonely": 0, "disappointed": 0,

    "terrified": 0, "nostalgic": 0, "devastated": 0, "annoyed": 0,

    # Neutral

    "neutral": 1, "surprised": 1, "confused": 1, "anticipating": 1, "apprehensive": 1,

    "hopeful": 1, "caring": 1, "sentimental": 1,

    # Positive

    "happy": 2, "excited": 2, "content": 2, "grateful": 2, "proud": 2, "impressed": 2,

    "joyful": 2, "trusting": 2, "prepared": 2, "confident": 2

}

df2['label'] = df2['emotion'].map(emotion2label).fillna(1).astype(int)

ds2 = Dataset.from_pandas(df2[['text', 'label']])
```

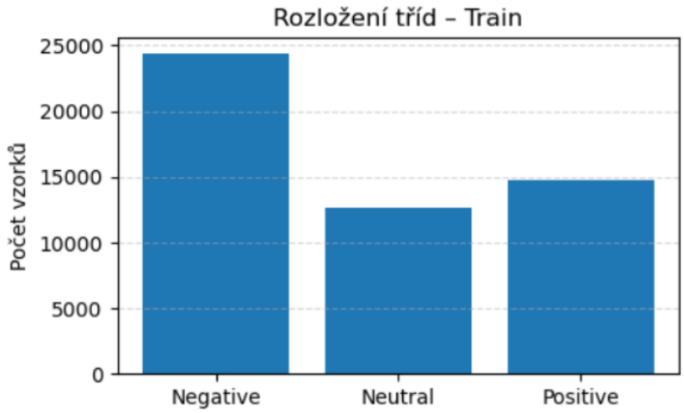
Část kódu 2: Rozdělení emocí do 3 tříd

Analýza zastoupení jednotlivých sentimentů

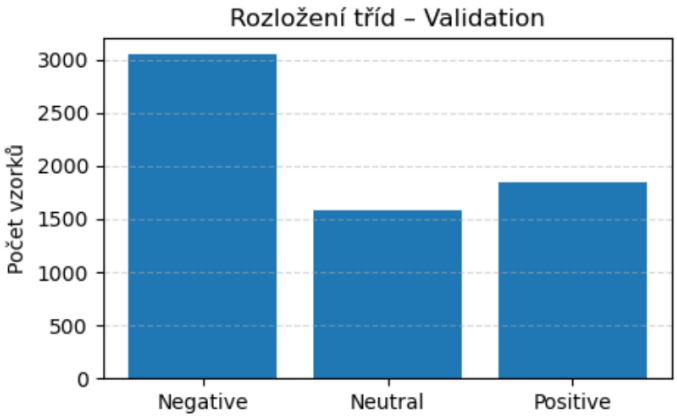
Obdobným způsobem jako u předchozího datasetu byla provedena analýza rozložení sentimentů u datasetu empathetic_dialogues. Cílem bylo zjistit, zda jsou jednotlivé sentimentální třídy (pozitivní, negativní a neutrální) zastoupeny vyváženě, což je důležité pro stabilní trénování modelu a pro minimalizaci rizika, že by model mohl preferovat některou třídu na úkor jiných.

Analýza ukázala, že třídy jsou v datasetu relativně vyvážené, což znamená, že počet příkladů v každé kategorii je přibližně srovnatelný. Takové rozložení je vhodné pro trénink modelu, protože snižuje možnost vzniku zkreslení (biasu) a zajišťuje, že model má dostatek dat pro všechny kategorie sentimentů. Na základě této vyváženosti lze dataset považovat za adekvátní pro další fine-tuning modelu, což podporuje jeho schopnost správně klasifikovat různé emocionální projevy v konverzacích.

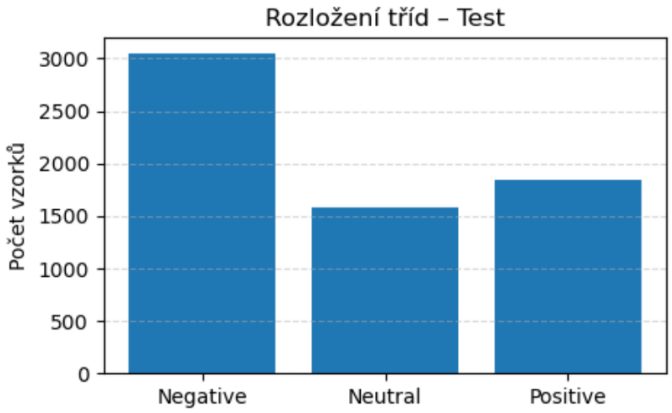
Následující tři grafy ilustrují rozložení jednotlivých sentimentů v datasetu a vizuálně ukazují jejich zastoupení v trénovací, validační a testovací sadě.



Obrázek 4: Train - Class distribution: Negative: 24355 (47,10 %) Neutral : 12640 (24,44 %) Positive: 14713 (28,45 %)
Zdroj: Autorské zpracování



Obrázek 5: Validation - Class distribution: Negative: 3045 (47,11 %) Neutral : 1580 (24,44 %) Positive: 1839 (28,45 %)
Zdroj: Autorské zpracování



Obrázek 6: Test - Class distribution: Negative: 3044 (47,09 %) Neutral : 1580 (24,44 %) Positive: 1840 (28,47 %)
Zdroj: Autorské zpracování

Nastavení tréninku

Jak bylo uvedeno v první etapě, bylo nutné při tréninku uplatnit stejnou logiku vyvažování tříd, jaká byla použita v prvním skriptu. Tento postup zajišťuje rovnoměrné zastoupení jednotlivých sentimentů během tréninku, čímž se minimalizuje riziko zkreslení modelu a zároveň se podporuje správná klasifikace sentimentů. Díky tomu model získává vyváženou znalost všech tří kategorií a jeho predikce jsou spolehlivější a konzistentnější.

Výsledky

Výsledky ukazují, že model, který byl dotrénován na základě modelu z první etapy s názvem roberta-sentiment_dataset1, byl úspěšně vylepšen a následně uložen pod

názvem roberta-sentiment_dataset2v2 (viz příloha A.3).

Jak je patrné z tabulek níže, trénování modelu proběhlo lépe, což se odráží ve zlepšení F1 skóre i dalších sledovaných metrik, jako jsou přesnost (accuracy), úplnost (precision) a výtěžnost (recall). Tyto výsledky naznačují, že model lépe zvládá rozlišovat mezi jednotlivými sentimenty v rámci trénovacího procesu.

Nejdůležitějším krokem pro ověření, zda je model uspokojivě natrénován, je test na nezávislých datech. Z těchto výsledků je však patrné, že model zatím nedokáže spolehlivě přiřadit některé případy k labelu „Neutral“. To značí potřebu další etapy fine-tuningu, která by měla zajistit lepší rozpoznávání neutrálního sentimentu, a tím zvýšit celkovou kvalitu predikcí modelu.

Tabulka 9: Výsledky vyhodnocení modelu na testovacích datech (roberta-sentiment_dataset2v2)

Metrika	**Hodnota**
Eval loss	0,2030
Accuracy	0,9561
Precision	0,9560
Recall	0,9561
F1-score	0,9560
Runtime (s)	12,2076
Vzorky za sekundu	529,5060
Kroky za sekundu	33,0940
Počet epoch	3

Tabulka 10: Ukázka predikcí sentimentu modelu (roberta-sentiment_dataset2v2)

Text	**Negative**	**Neutral**	**Positive**
I am so happy today! Everything went perfectly.	0,0001	0,0009	**0,9990**
I feel so sad and disappointed.	**0,9987**	0,0012	0,0001
It's just an ordinary day, nothing special happened.	0,0100	0,4221	**0,5678**
I'm frustrated and angry about this situation.	**0,9957**	0,0041	0,0002
I'm nervous about tomorrow's meeting.	**0,9892**	0,0105	0,0003

2.6 Finální etapa – Chat Sentiment Dataset

Pro finální doladění modelu bylo nutné zaměřit se na klasifikaci jednodušších textů, u kterých se v předchozích etapách nejčastěji objevovaly problémy s určením sentimentu, zejména v případě neutrální třídy. Z tohoto důvodu byl model dále trénován na posledním datasetu s názvem „Chat Sentiment Dataset“, který byl obdobně jako ve druhé etapě použit ve formě CSV souboru staženého z platformy Kaggle.

Tento dataset byl zvolen záměrně, jelikož je primárně určen pro úlohu určování sentimentu a obsahuje jasně definované kategorie sentimentů. Díky tomu je velmi vhodný pro finální doladění modelu, jehož cílem bylo zpřesnit rozhodování v hraničních případech a zvýšit celkovou spolehlivost klasifikace.

Transformace dat pro trénink

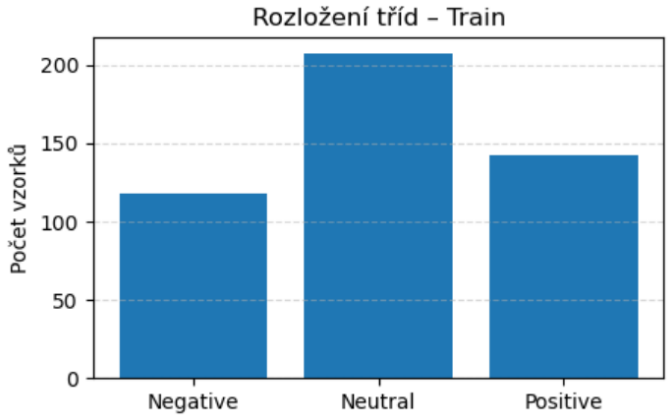
Výhodou tohoto datasetu je skutečnost, že již obsahuje předem rozdělené sentimenty do tří základních kategorií. Pro zachování sjednocení s předchozími verzemi dat bylo nutné provést již pouze přejmenování názvů sloupců, konkrétně sloupce „message“ na „text“ a sloupce „sentiment“ na „label“. Tento krok zajistil kompatibilitu datasetu s existujícími skripty pro trénování modelu a umožnil jeho bezproblémové další zpracování.

Analýza zastoupení jednotlivých sentimentů

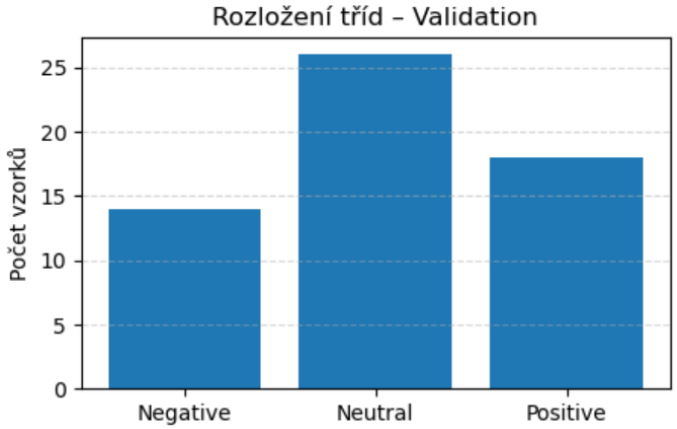
Stejně jako v předchozích etapách byla i zde provedena analýza zastoupení jednotlivých sentimentů, jejímž cílem bylo ověřit správné rozložení tříd a vyloučit možnost chybného označení labelů v datasetu.

Z následujících grafů je patrné, že sentiment typu „Neutral“ je v tomto datasetu zastoupen ve větší míře než ostatní sentimenty, což je pro tuto fázi velmi přínosné. Právě zvýšené zastoupení neutrální třídy činí tento dataset ideálním pro konečné

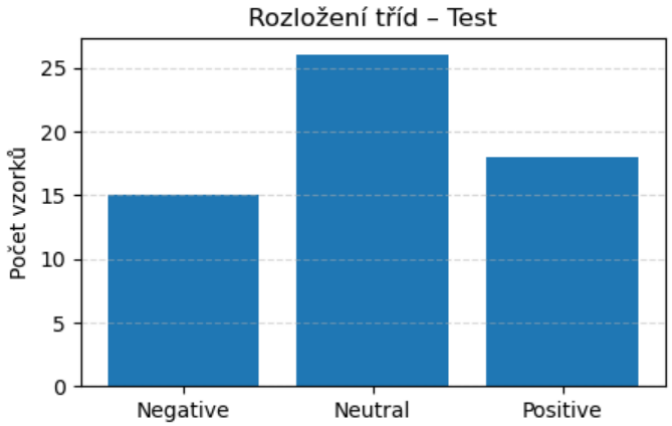
dotrénování modelu, a to zejména s ohledem na její slabší zastoupení v předchozím testování.



Obrázek 7: Train - Class distribution: Negative: 118 (25,27 %) Neutral : 207 (44,33 %) Positive: 142 (30,41 %)
Zdroj: Autorské zpracování



Obrázek 8: Validation - Class distribution: Negative: 14 (24,14 %) Neutral : 26 (44,83 %) Positive: 18 (31,03 %)
Zdroj: Autorské zpracování



Obrázek 9: Test - Class distribution: Negative: 15 (25,42 %) Neutral : 26 (44,07 %) Positive: 18 (30,51 %)
Zdroj: Autorské zpracování

Výsledky

Finální fází tréninku je model pojmenovaný „roberta-sentiment_dataset3“ (viz příloha A.4). Z dosažených výsledků vyplývá, že model natrénovaný na finálním datasetu dosáhl sice horších hodnot F1 skóre a dalších sledovaných metrik ve srovnání s předchozí etapou, tento pokles lze však vysvětlit zejména odlišnou strukturou dat a větším důrazem na specifické typy textů, především na neutrální vyjádření.

Z hlediska celkového cíle práce je však klíčovým ukazatelem chování modelu na testovacích textech, které nebyly součástí trénovacích dat. Tyto testy ukázaly, že neutrální sentiment je již přiřazován správným způsobem, což bylo hlavním problémem v předchozích etapách. Z tohoto důvodu lze tuto finální fázi trénování považovat za úspěšnou, jelikož odstranila zásadní nedostatek v klasifikaci sentimentu a zvýšila praktickou využitelnost výsledného modelu.

Dosažené výsledky této finální etapy jsou přehledně shrnuty v tabulkách uvedených níže, které uvádějí konkrétní hodnoty jednotlivých sledovaných metrik.

Tabulka 11: Výsledky vyhodnocení modelu na testovacích datech (roberta-sentiment_dataset3)

Metrika	**Hodnota**
Eval loss	0,3346
Accuracy	0,9153
Precision	0,9160
Recall	0,9153
F1-score	0,9152
Runtime (s)	0,1259
Vzorky za sekundu	468,5930
Kroky za sekundu	31,7690
Počet epoch	3

Tabulka 12: Ukázka predikcí sentimentu modelu (roberta-sentiment_dataset3)

Text	**Negative**	**Neutral**	**Positive**
I am so happy today! Everything went perfectly.	0,0003	0,0046	**0,9951**
I feel so sad and disappointed.	**0,9963**	0,0036	0,0002
It's just an ordinary day, nothing special happened.	0,0003	**0,9977**	0,0020
I'm frustrated and angry about this situation.	**0,9949**	0,0049	0,0002
I'm nervous about tomorrow's meeting.	**0,8636**	0,1349	0,0014

2.7 Shrnutí

V rámci implementace, jak bylo ukázáno výše, došlo k úspěšnému natrénování a fine-tuningu modelu pro automatické určování sentimentu textových zpráv. Postupné dolaďování modelu na různorodých datech umožnilo zlepšit jeho schopnost správně klasifikovat pozitivní, neutrální i negativní sentiment, což je patrné z dosažených metrik přesnosti a analýzy chyb.

Pro komplexní vyhodnocení dosažených výsledků je však nezbytné provést detailní testování na nezávislých testovacích datech. Tento proces zahrnuje nejen vyhodnocení celkové přesnosti, ale i analýzu typů chyb, vizualizaci výsledků pomocí matic záměn a porovnání s existujícími „pre-trained“ modely. Podrobná analýza je následně rozebrána v následující sekci věnované testování modelu, která poskytuje hlubší pohled na jeho výkon a oblasti, ve kterých může být dále optimalizován.

2.8 Testování

Tato kapitola se zaměřuje na podrobné testování natrénovaného modelu, jehož cílem je ověřit, zda jednotlivé fáze tréninku proběhly úspěšně a zda docházelo k postupnému zlepšování jeho schopností. K testování byly využity různé metody hodnocení výkonu modelu, které umožňují sledovat jeho chování v jednotlivých fázích vývoje.

Součástí testování je nejen samotné ověření funkčnosti modelu, ale také porovnání výsledků mezi jednotlivými trénovacími etapami, na základě kterého je možné posoudit, zda provedené úpravy a jednotlivé kroky fine-tuningu vedly ke zlepšení, případně kde se nadále vyskytují slabší místa. Tato kapitola tak poskytuje ucelený pohled na výkonnost výsledného řešení a jeho připravenost pro praktické použití.

Příprava testovacích dat

Pro praktické ověření schopnosti natrénovaného modelu správně určovat sentiment jednotlivých zpráv bylo nezbytné využít externí testovací datové sady, které nebyly součástí trénovacího procesu. V rámci tohoto experimentu byly připraveny tři nezávislé testovací sady. První sada byla vygenerována pomocí nástroje ChatGPT a uložena ve formátu chat_dataset.csv. Druhá testovací sada vznikla za využití modelu Gemini a nese označení test2.csv. Třetí sada byla převzata z veřejně dostupné knihovny na platformě Hugging Face, konkrétně „chat-gpt-sentiment_preprocess“. Tyto datové sady umožnily objektivní porovnání výkonnosti modelu na různorodých a nezávislých datech.

Skript pro testování modelu

Pro účely vyhodnocení byl vytvořen samostatný testovací skript (viz příloha A.5), ve kterém je načten zvolený natrénovaný model spolu s příslušnou testovací datovou sadou. Skript následně provede vyhodnocení celkového počtu testovaných vět a vypočítá dosaženou přesnost klasifikace. V další části jsou zobrazeny náhodně vybrané ukázky výsledků, konkrétně deset různých klasifikovaných případů. Samostatně je rovněž vypsáno deset náhodně zvolených příkladů, ve kterých model klasifikoval sentiment chybně.

V závěrečné části vyhodnocení jsou analyzovány nejčastější typy klasifikačních chyb, které jsou přehledně znázorněny pomocí matice záměn. Kromě toho je vykreslen i graf přesnosti měření, jenž slouží ke grafickému porovnání výsledků jednotlivých testovaných modelů.

Testování na testovacích datových sadách

V rámci testování bylo původně zamýšleno využít tři testovací datové sady samostatně. Z důvodu lepší přehlednosti a efektivnějšího vyhodnocení byly však tyto tři sady následně sloučeny do jediné společné testovací množiny (viz příloha A.6). Tím odpadla nutnost provádět testování odděleně a zároveň bylo umožněno jednot-

né porovnání dat pocházejících z různých zdrojů v rámci jednoho vyhodnocovacího procesu. Výsledná testovací sada tak obsahovala celkem 1 573 unikátních textových vzorků, které byly použity pro finální testování modelu.

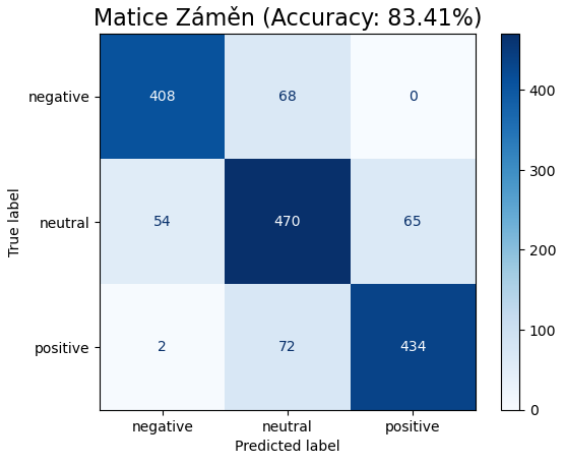
Matice záměn V rámci testování na testovacích datech pocházejících z trénovacího datasetu byla použita matice záměn, která slouží k podrobnému vyhodnocení správnosti klasifikace v jednotlivých třídách. Tato metoda umožňuje přehledně znázornit, jakým způsobem model přiřazoval jednotlivé vzorky k odpovídajícím kategoriím a zda bylo jejich zastoupení v jednotlivých fázích klasifikace vyhodnoceno správně. Zároveň poskytuje detailní informace o počtech správných i nesprávných predikcí a umožňuje identifikovat nejčastější typy chyb mezi jednotlivými třídami.

První verze modelu dosáhla uspokojivých výsledků, což je patrné i ze samotné matice záměn. Výsledky ukazují, že míra chybovosti je napříč jednotlivými třídami přibližně vyrovnaná. Na základě tohoto zjištění se potvrdilo, že model sice dosahuje stabilních výsledků, avšak jeho další zlepšení vyžaduje dodatečné doladění na rozšířeném a rozmanitějším datovém souboru.

Tabulka 13: Nejčastější typy chyb modelu verze 1

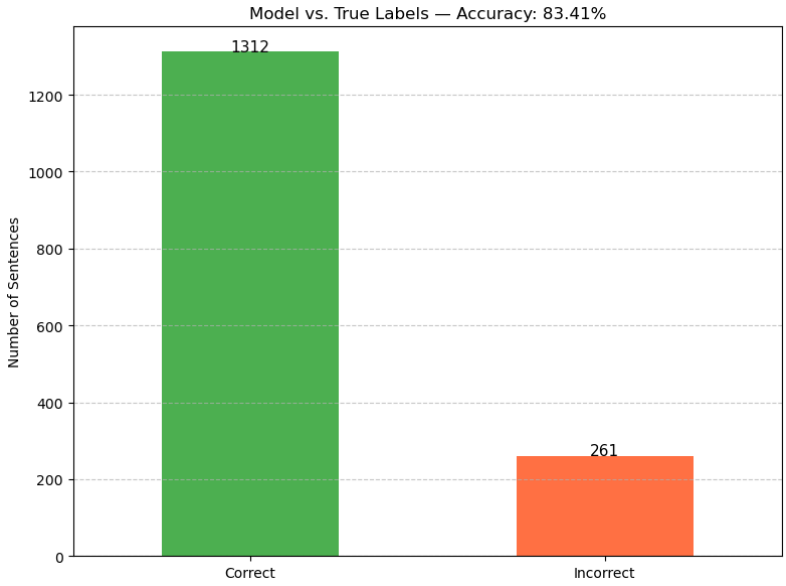
Typ chyby	**Počet výskytů**
positive → neutral	72
negative → neutral	68
neutral → positive	65
neutral → negative	54
positive → negative	2

Jak je patrné z matice záměn, model dosáhl celkové přesnosti (accuracy) ve výši 83,41 %. Tento výsledek lze považovat za uspokojivý, zejména s ohledem na skutečnost, že se jedná o počáteční verzi modelu. Zároveň je z matice záměn patrné, že chybovost je mezi jednotlivými třídami sentimentu relativně vyrovnaná, což naznačuje, že model není výrazně zaujat vůči žádné konkrétní třídě a vykazuje stabilní klasifikační chování.



Obrázek 10: Matice záměn první verze modelu

Následující graf znázorňuje grafické srovnání výkonu modelu a jeho celkovou přesnost.



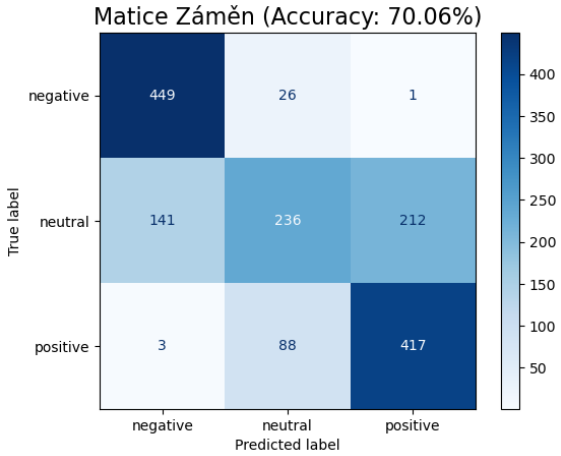
Obrázek 11: Přesnost určení sentimentu na první verzi modelu

Druhá verze modelu ukázala, jak je patrné z níže uvedených výsledků, nižší celkovou přesnost klasifikace, konkrétně došlo k poklesu o 13,35 %. Na základě analýzy matice záměn se ukázalo, že model má výrazné obtíže zejména při rozlišování neutrálního sentimentu, který je v řadě případů chybně predikován jako pozitivní či negativní. Toto zkreslení naznačuje nedostatečné zastoupení neutrálních vzorků v trénovacích datech. Na základě těchto zjištění bylo rozhodnuto model zachovat a dále jej dotrénovat na datovém souboru s vyšším zastoupením neutrálního labelu s cílem zvýšit jeho vyváženost a celkovou přesnost predikce.

Tabulka 14: Nejčastější typy chyb modelu verze 2

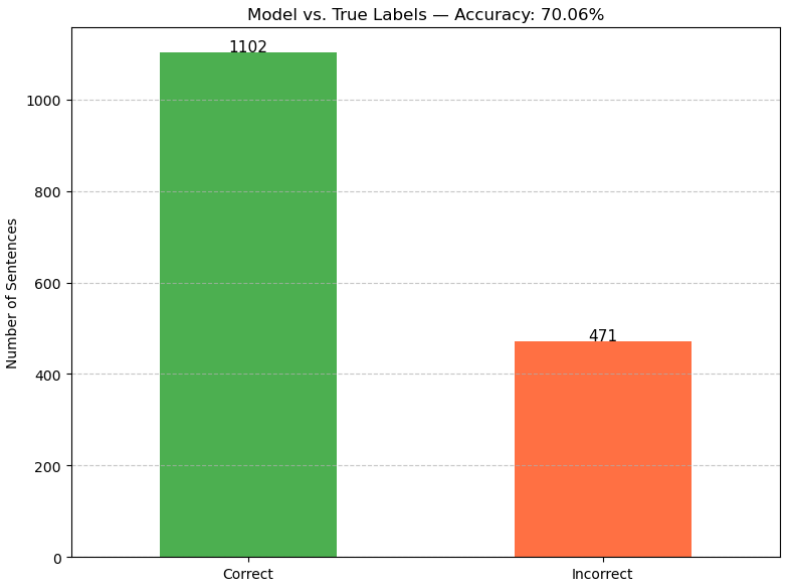
Typ chyby	**Počet výskytů**
neutral → positive	212
neutral → negative	141
positive → neutral	88
negative → neutral	26
positive → negative	3

Z uvedené matice záměn vyplývá, že model dosáhl celkové přesnosti 70,06 %. Nejvyšší míra chybovosti byla zaznamenána u neutrálního sentimentu, který byl nesprávně klasifikován celkem ve 353 případech.



Obrázek 12: Matice záměn druhá verze modelu

Níže uvedený graf znázorňuje výsledky klasifikace sentimentu, z nichž vyplývá, že model správně klasifikoval 1102 testovacích textů, zatímco ve 471 případech došlo k nesprávnému určení.



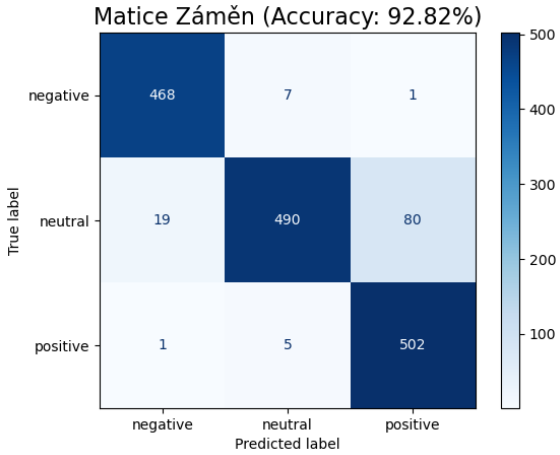
Obrázek 13: Přesnost určení sentimentu na druhé verzi modelu

Finální verze modelu dosáhla na testovacích datech celkové přesnosti až 92,82 %, což představuje výrazné zlepšení oproti předchozím verzím. Tento výsledek potvrzuje, že proces postupného dolaďování a rozšiřování trénovacích dat vedl k úspěšnému natrénování modelu a k výraznému zlepšení jeho klasifikačních schopností. Na základě dosažených výsledků lze konstatovat, že model je vhodný pro praktické využití při automatickém určování sentimentu textových zpráv. Zároveň vytváří prostor pro další budoucí rozšíření, například formou dalšího dotrénování na rozsáhlejších datech nebo adaptace na jiné jazykové domény.

Tabulka 15: Nejčastější typy chyb modelu finální verze

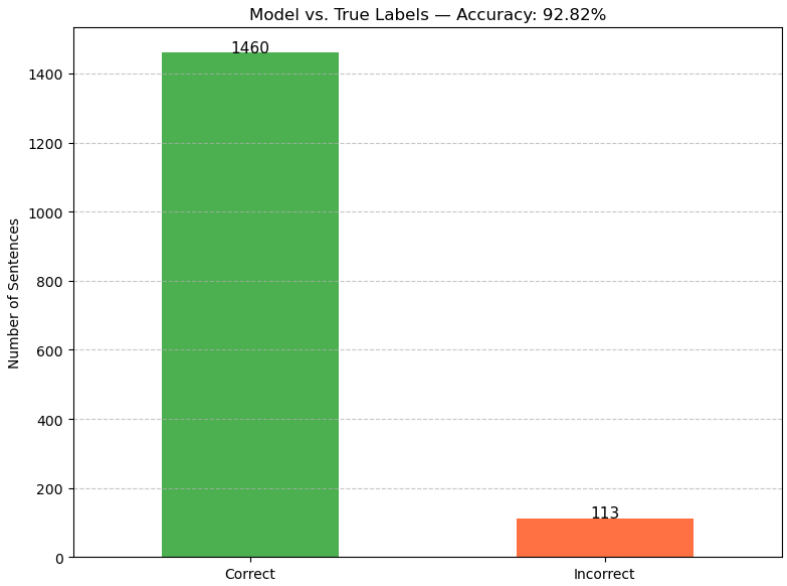
Typ chyby	**Počet výskytů**
neutral → positive	80
neutral → negative	19
negative → neutral	7
positive → neutral	5
positive → negative	1

Z matice záměn finální verze modelu je patrné výrazné zlepšení klasifikační přesnosti, která se oproti předchozí verzi zvýšila o 22,76 %. Analýza chyb dále ukazuje, že nejčastější nepřesnost spočívala v nesprávném přiřazení pozitivního sentimentu ke třídě neutrální, a to v 80 případech. Vzhledem k celkovému počtu testovacích vzorků lze tuto míru chybovosti považovat za přijatelnou a potvrzující stabilní výkon modelu.



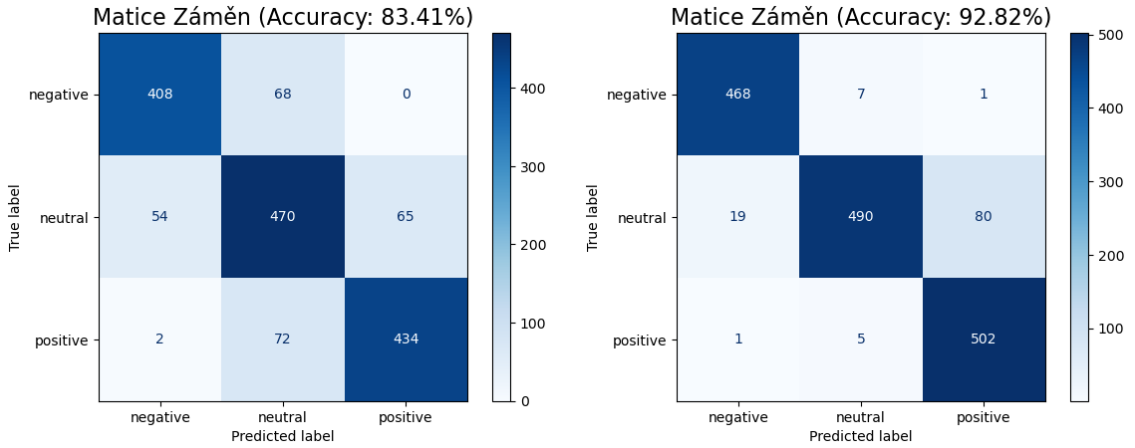
Obrázek 14: Matice záměn finální verze modelu

Následující graf znázorňuje výsledky klasifikace sentimentu finální verze modelu, z nichž vyplývá, že správného určení sentimentu bylo dosaženo ve 1460 případech, zatímco k chybnému určení došlo ve 113 případech.

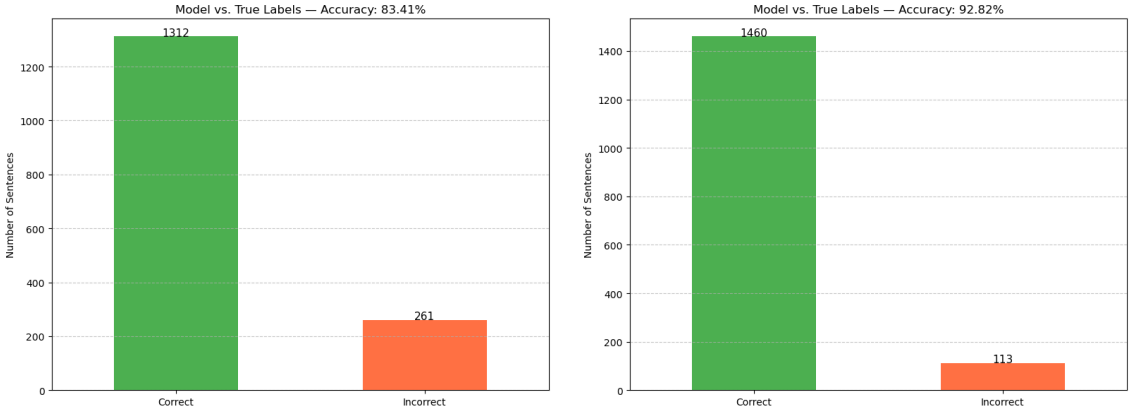


Obrázek 15: Přesnost určení sentimentu u finální verze modelu

Porovnání finální verze modelu s první verzí Pro lepší pochopení rozdílů mezi jednotlivými fázemi tréninku modelu je zde uvedeno srovnání výsledků první verze modelu s finální verzí. Toto porovnání umožňuje vizuálně sledovat zlepšení přesnosti klasifikace a změny v chybovosti mezi verzemi.



Obrázek 16: Matice záměn: první verze modelu (vlevo) a finální verze modelu (vpravo)

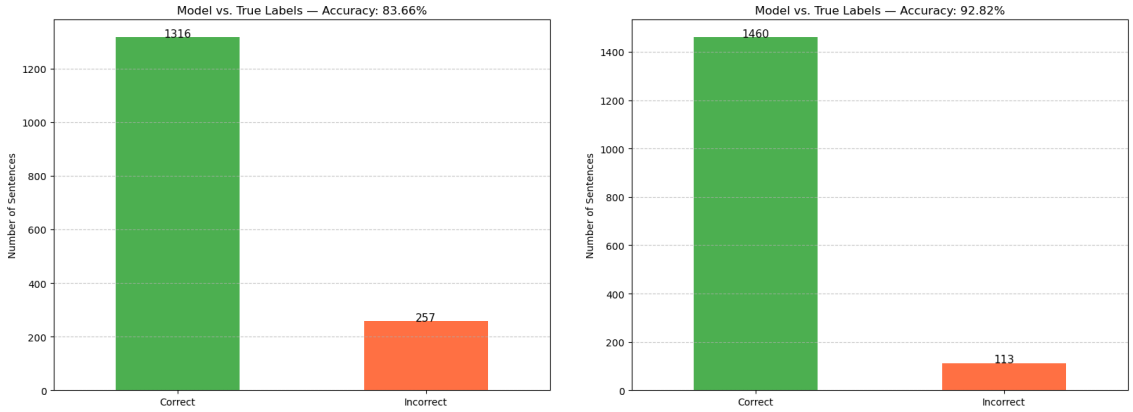


Obrázek 17: Přesnost určení sentimentu u první verze modelu (vlevo) a finální verze modelu (vpravo)

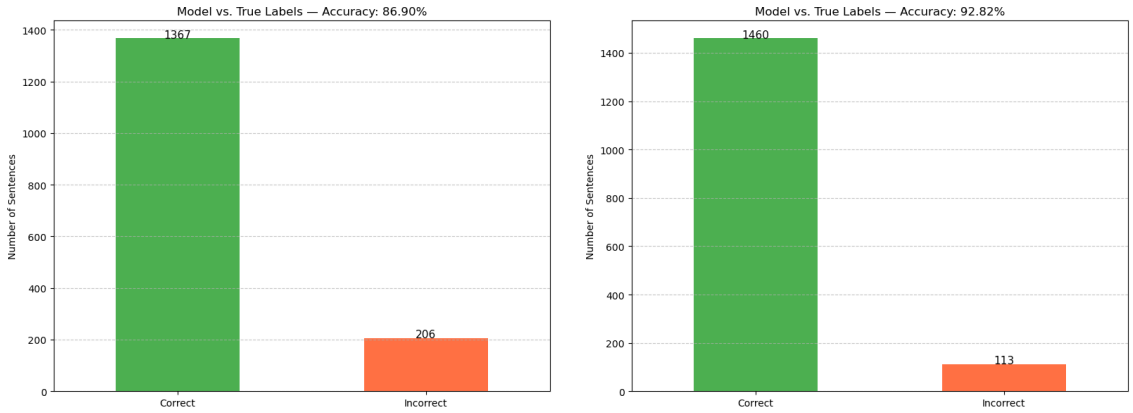
Srovnání s již existujícími modely V rámci testování byla provedena i kontrola, zda již existující předtrénované modely dokáží dosáhnout lepších výsledků než námi vytvořený model „roberta-sentiment_dataset3“. Pro toto srovnání byly vybrány dva externí modely: „cardiffnlp/twitter-roberta-base-sentiment-latest“ a „j--hartmann/sentiment-roberta-large-english-3-classes“. Cílem bylo ověřit jejich funkčnost a porovnat jejich výkon s modelem vyvinutým v rámci této práce.

V následujícím vizuálním srovnání je patrný rozdíl mezi výsledky externího modelu (zobrazeného nalevo) a natrénovaného modelu práce (zobrazeného napravo).

Toto porovnání umožňuje rychle identifikovat, v čem se model vyvinutý v rámci práce liší od předtrénovaných variant a zda dokáže konkurovat existujícím řešením v oblasti klasifikace sentimentu.



Obrázek 18: Srovnání přesnosti určení sentimentu modelu „twitter-roberta-base-sentiment-latest“ (vlevo) a natrénovaného modelu (vpravo)



Obrázek 19: Srovnání přesnosti určení sentimentu modelu „sentiment-roberta-large-english-3-classes“ (vlevo) a natrénovaného modelu (vpravo)

Shrnutí

V rámci testování bylo potvrzeno, že došlo k úspěšnému fine-tuningu modelu pro automatické určování sentimentu. Natrénovaný model prokázal vysokou schopnost správné klasifikace jednotlivých sentimentů – pozitivního, neutrálního i negativního – a to nejen z hlediska celkové přesnosti, ale i při analýze specifických typů chyb.

Kromě toho bylo zjištěno, že model dosahuje vyšší přesnosti při určování samostatných sentimentů než předtrénované modely z komunity Hugging Face, které jsou založeny na architektuře RoBERTa. Detailní srovnání ukázalo, že finální verze modelu lépe zvládá rozlišovat neutrální sentiment, který bývá častou slabinou

existujících modelů, a zároveň vykazuje nižší míru chyb při predikci pozitivního a negativního sentimentu.

Celkově tedy testování potvrdilo, že navržený a natrénovaný model je vhodný pro praktické použití při analýze sentimentu textových zpráv a poskytuje spolehlivý základ pro další možné rozšíření či adaptaci na jiné domény a jazykové varianty.

3 Literatura

Géron, A. (2019). Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow. 2. vyd., O'Reilly Media, 2019.

Yuncongli. Chat Sentiment Analysis Dataset. [online]. Dostupné z: https://huggingface.co/datasets/yuncongli/chat-sentiment-analysis.

Facebook AI. Empathetic Dialogues. [online]. Dostupné z: https://huggingface.co/datasets/facebook/empathetic_dialogues.

Maibaum, S. Conversation Emotion Dataset. [online]. Dostupné z: https://huggingface.co/datasets/Svenni551/conversation-emotion-dataset.

Fanqiwan. DistillChat V1 Dataset. [online]. Dostupné z: https://www.kaggle.com/datasets/thedevastator/distillchat-v1-mixture-of-conversations-dataset/data.

GeeksforGeeks (2025). Best Tools for Natural Language Processing in 2025. [online]. Dostupné z: https://www.geeksforgeeks.org/nlp/best-tools-for-natural-language-processing-in-2024/.

Spot Intelligence (2024). NLP Tools Overview. [online]. Dostupné z: https://spotintelligence.com/2024/01/29/natural-language-processing-nlp-tools/.

Hugging Face (2022). Transformers Documentation. [online]. Dostupné z: https://huggingface.co/docs/transformers/v4.17.0/en/index [cit. 20.07.2025].

Didin, J. (2025). Top 10 open source AI tools. Djamware. [online]. Dostupné z: https://www.djamware.com/post/6870bb57dfc97b454e8dec27/top-10-open-source-ai-tools-every-developer-should-know-2025-edition.

CESNET (2025). MetaVO User Portal. [online]. Dostupné z: https://metavo.metacentrum.cz/.

Kotamraju, S. (2022). ALBERT vs RoBERTa vs DistilBERT. Towards Data Science. [online]. Dostupné z: https://towardsdatascience.com/everything-you-need-to-know-about-albert-roberta-and-distilbert-11a74334b2da/.

Swiftorial (2025). BERT vs RoBERTa vs DistilBERT comparison. [online]. Dostupné z: https://www.swiftorial.com/matchups/nlp_platforms/bert-vs-roberta-vs-distilbert.

Přílohy

A Skripty

Přehled všech skriptů, datových sad a experimentů použitých při realizaci analýzy sentimentu. Veškerý kód je dostupný v GitHub repozitáři: `https://github.com/vojmahdal/sentiment_analysis`

A.1 Etapa 1 – skript pro trénink prvního datasetu

Základní experiment s prvním datasetem včetně jeho předzpracování a tréninku modelu. `https://github.com/vojmahdal/sentiment_analysis/tree/main/version_1`

soubor: train.ipynb

A.2 Etapa 1.2 – skript pro trénink prvního datasetu 2. verze

Vylepšená verze experimentu nad prvním datasetem s využitím modelu RoBERTa a optimalizovaného nastavení tréninku.

`https://github.com/vojmahdal/sentiment_analysis/tree/main/version_3`

soubor: roberta-sentiment_dataset1.ipynb

A.3 Etapa 2 – skript pro trénink druhého datasetu

Experiment zaměřený na druhý dataset zahrnující úpravu dat a trénink modelu pro porovnání výsledků.

`https://github.com/vojmahdal/sentiment_analysis/tree/main/version_4`

soubor: roberta-sentiment_dataset2v2.ipynb

A.4 Etapa 3 – skript pro trénink třetího datasetu

Finální experimenty nad třetím datasetem vedoucí k vytvoření výsledného modelu.

`https://github.com/vojmahdal/sentiment_analysis/blob/main/version_6`

soubor: 14_11_train_third.ipynb, roberta-sentiment_dataset3.ipynb

A.5 Testování

Skript sloužící k finálnímu otestování natrénovaného modelu na oddělené testovací sadě.

`https://github.com/vojmahdal/sentiment_analysis/tree/main/final_test`

soubor: test_final.ipynb

A.6 Testovací sada

Dataset použitý pro nezávislé vyhodnocení kvality modelu.

`https://github.com/vojmahdal/sentiment_analysis/tree/main/final_test`

soubor: dataset_final_test.csv

B JupyterHub

Prostředí potřebné pro spuštění experimentů a trénování modelů.

B.1 Platforma JupyterHub

Platforma umožňující spouštění Jupyter notebooků na vzdálených výpočetních zdrojích.

`https://hub.cloud.e-infra.cz/`

B.2 MetaCentrum

Poskytovatel výpočetních zdrojů, skrze kterého je možné získat přístup k prostředí JupyterHub.

Registrace: `https://metavo.metacentrum.cz/en/application/form`

B.3 Dokumentace

Oficiální dokumentace k nastavení a používání platformy JupyterHub.

`https://docs.cerit.io/en/docs/web-apps/jupyterhub`

B.4 Instalační soubor

Skript pro vytvoření virtuálního prostředí, které je možné použít v prostředí JupyterLab, a instalaci potřebných knihoven pro běh projektu.

`https://github.com/vojmahdal/sentiment_analysis/blob/main`
soubor: setup_venv_transformers.sh